LIVRABLE TEST TECHNIQUE

Partie 1	Partie 2
Agent LangGraph + Excel	Architecture OVH Cloud Souverain

Stack imposée : LangGraph · OpenRouter · arcee-ai/trinity-large-preview (gratuit)

PARTIE 1 — AGENT AGENTIQUE EXCEL (PHARMA)

1.1 Livrables Partie 1

- Code source disponnible sur mon GitHub
- Les intructions de lancement sont disponnible dans le fichier ‘README.md’

1.3 Stack technique

Stack
LLM :
OpenRouter → arcee-ai/trinity-large-preview:free (gratuit, aucune clé API payante requise)
Orchestration :
LangGraph (framework de graphe agentique)
Excel :
openpyxl (enregistrement) et pandas (lecture/calcul)
Language :
Python 3.11
Interface :
Streamlit + FastAPI (local, docker compose, kubernetes distant)

1.4 Architecture LangGraph

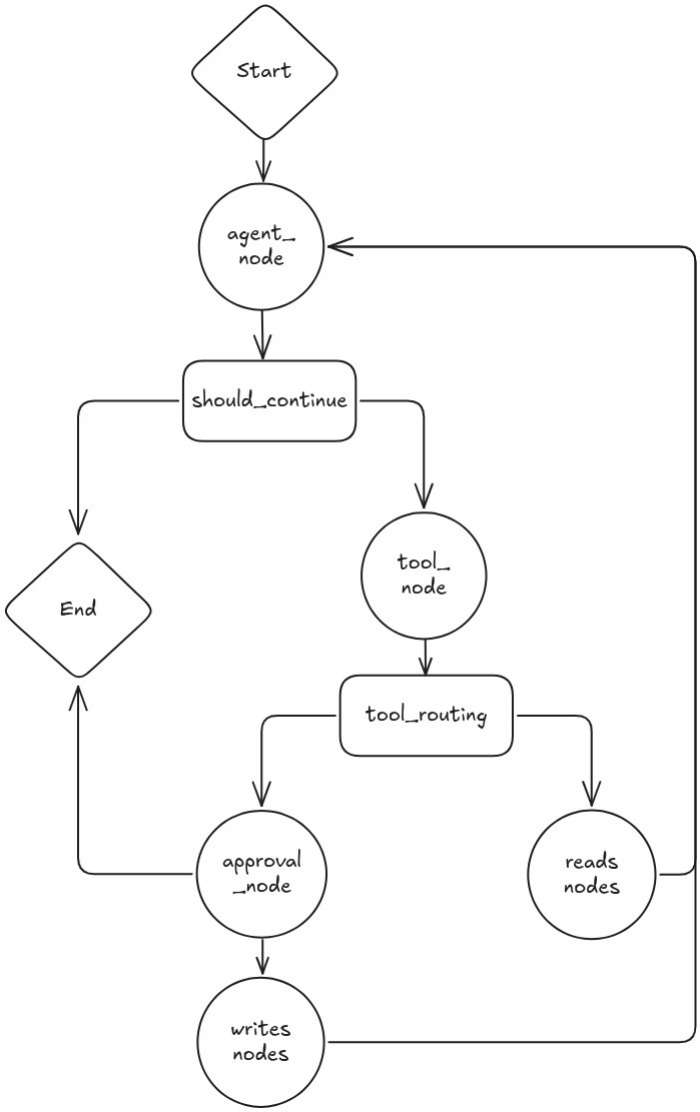

PARTIE 2 — ARCHITECTURE OVH CLOUD SOUVERAIN

2.1 Livrable attendu

Pour l'architecture de déploiement, chez OVH Cloud hébergé en France, on déploie notre application (api et front) dans un cluster Kubernetes via le Managed Kubernetes Service qui permet une bonne scalabilité (horizontale et verticale) et une gestion des secrets couplée avec le service Secret Manager de OVH. On utilise un Load Balancer pour répartir la charge (avec nginx pour reverse proxy). Les images sont stockées dans le Managed Private Registry d'OVH. Et les données (utilisateur et checkpointer langgraph) sont stockées dans une base de données PostgreSQL 17.

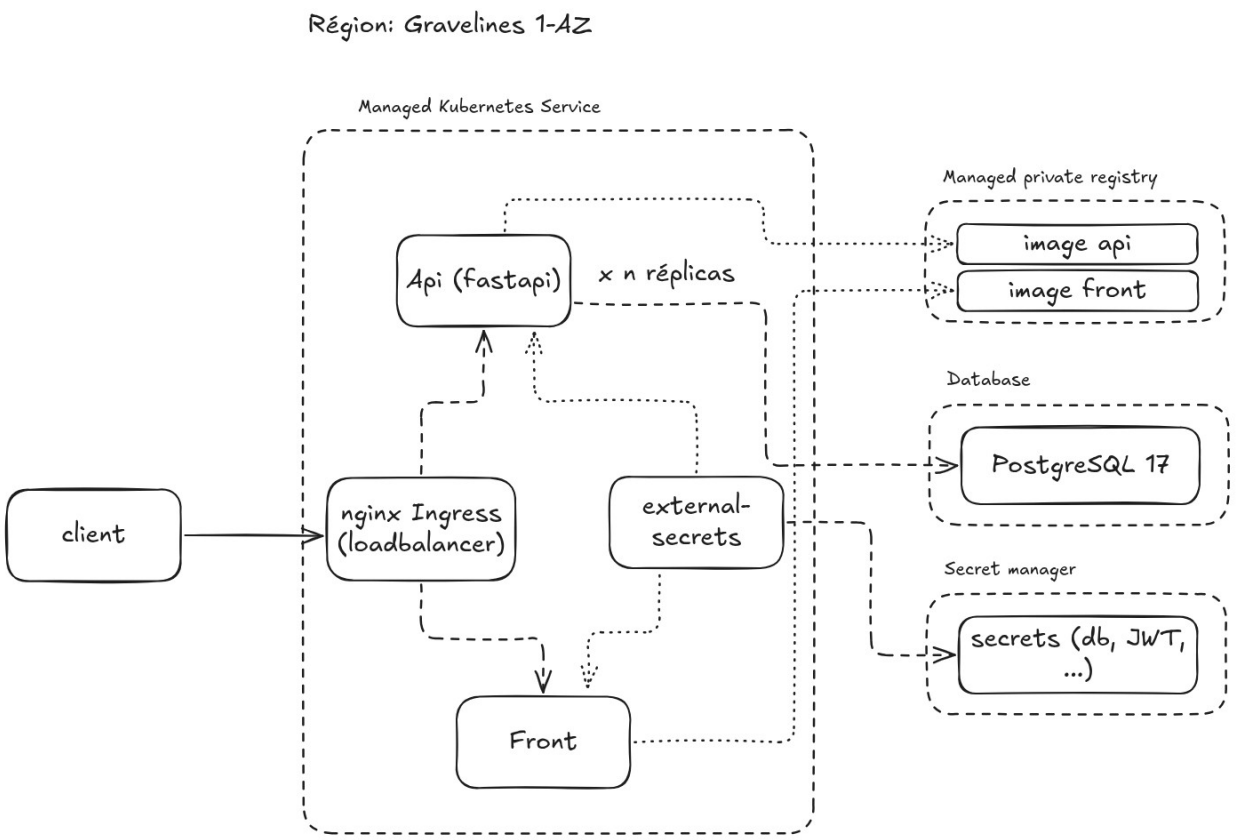

Spécification:

- Région: Gravelines 1-az
- Managed Kubernetes Service: service: Gratuit, noeud: 3x B3-8 (2vcore, 8Go RAM) 101.846/mois (possibilité de passer en région Paris 3-az pour avoir notre cluster répliqué + 65.70€/mois + prix noeud x nb_cluster)
- Database: PostgreSQL 17 production noeud:B3-8 (2vcore, 8Go RAM) prix: ~325€/mois
- Managed private registry: ~19.05€/mois
- Secret manager: 3 secrets: prix: 3 x 0.03€/mois = 0.09€/mois
- Load Balancer: taille M, prix: ~ 15.184€/mois

- GateWay: Taille S, prix: ~2.044€/mois
- IP floating: prix: 1.8€/mois

Total: ~ 465,464€/mois

Pour le LLM utilisé, on ne peut pas utiliser arcee-ai/trinity-large-preview:free, qui est pour le dev seulement et pas hébergé en Europe. Il y a plusieurs alternatives possibles : Si on n'a pas besoin d'une certification HDS pour les appels API (en UE) : on peut partir sur Mistral Large 3. Si on doit rester en France avec la certification HDS : on peut partir sur de l'auto-hébergement chez OVHcloud (AI Deploy) de Qwen3-235B NVFP4 sur 4x L40s (limité à des noeuds de 4 GPU) ou chez Scaleway (moins cher en général et max 8 GPU/noeud). Ce qui reste le plus économique sans quitter l'Europe reste l'API de Mistral mais hébergée chez Azure (acteur Américain) en Europe.